作業 01｜乳癌良性與惡性分類

姓名：周映妤 ｜ 學號：412570376 ｜ 系級：醫學資訊創新與應用學士學位學程 四年級 ｜繳交日期：10/29

摘要

這次作業我用 WDBC 乳癌資料的 30 項細胞核影像特徵，判斷腫瘤是良性 B 還是惡性 M。因為是醫療情境，所以我特別看惡性被判成良性的 False Negative。資料共 569 筆，B 357 筆、M 212 筆，沒有遺漏值。我先依類別分層，把資料切成 80% 訓練、20% 測試，前處理和 SVM 調參數都只用訓練集。最後四個模型的 Accuracy 都在 0.983 到 0.991 之間，FN 是 1 到 2 例，RBF-SVM 表現最好，不過模型之間只差 1 到 2 個個案。

> 執行環境 R version 4.6.1、MASS_7.3-65、compiler_4.6.1、class_7.3-23、tools_4.6.1、proxy_0.4-29、e1071_1.7-17。

1　資料理解與探索

每一筆資料是一位做過細針抽吸檢查的個案。資料量了十種細胞核特徵，例如 radius、texture、area、concavity，每一種又分成 mean、standard error、worst 三個版本，所以總共 30 個變數。Class 就是 B 或 M。

項目	結果	判讀
樣本數與類別比例	B = 357，佔 62.7%；M = 212，佔 37.3%	類別不完全平衡
遺漏值	0，訓練集和測試集都沒有	資料沒有遺漏值
特徵相關	|r| > 0.9 的特徵對共 21 組；最高是 mean radius 和 mean perimeter，r = 0.998	30 個特徵中有 21 組的相關係數超過 0.9，代表很多特徵其實在描述同一件事，可能會影響 LDA/QDA 共變異數估計

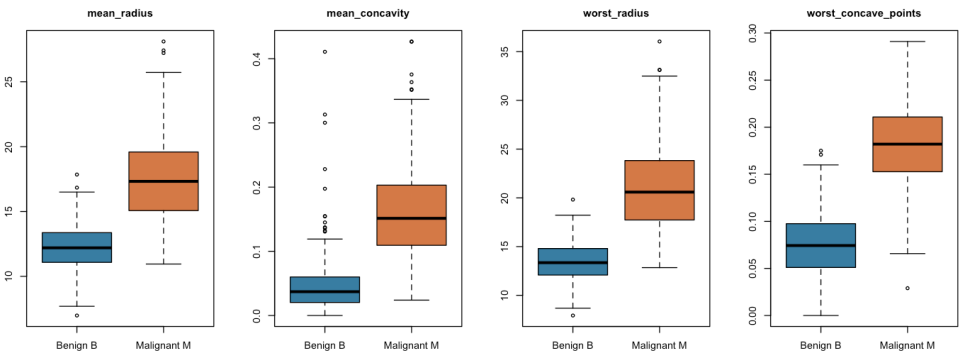
（表 1）資料基本資訊

我挑了四個和細胞核大小、凹陷程度有關的特徵，用 R 算出兩組的平均數、標準差、中位數和四分位數。從表 2 可以看到，M 組這四個特徵的平均數都比 B 組高很多。

變數	類別	平均數	標準差	中位數	Q1–Q3
mean radius	B	12.15	1.78	12.20	11.08–13.37
	M	17.46	3.20	17.33	15.08–19.59
mean concavity	B	0.046	0.043	0.037	0.020–0.060
	M	0.161	0.075	0.151	0.110–0.203
worst radius	B	13.38	1.98	13.35	12.08–14.80
	M	21.13	4.28	20.59	17.73–23.81
worst concave points	B	0.074	0.036	0.074	0.051–0.097
	M	0.182	0.046	0.182	0.153–0.211

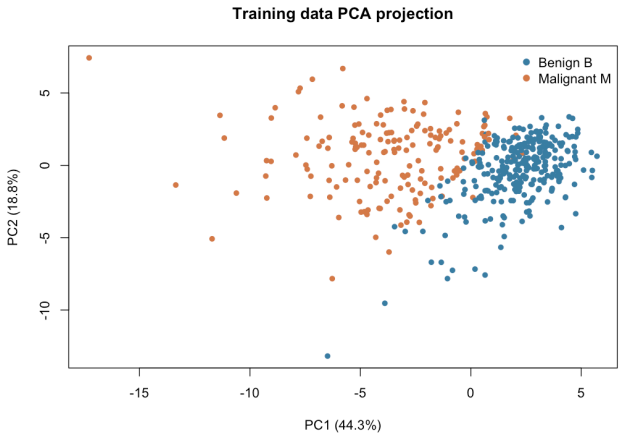
（表 2）重要預測變數在兩組中的分布，B 有 357 筆、M 有 212 筆

跑完 R 程式後產生了四個重要特徵的盒鬚圖，從圖 1 可以看到惡性組在大小和凹陷相關的指標都明顯比較高，數值也比較分散；mean concavity 在良性組是右偏的，而且有一些離群值。

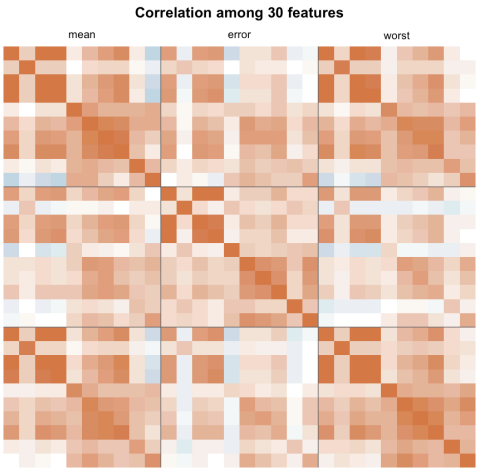


（圖 1）四個重要特徵在良性與惡性的盒鬚圖，藍色是良性、橘色是惡性

我也用 R 畫了訓練資料的 PCA 投影圖和 30 個特徵的相關熱圖。從圖 2 可以看到兩群大致沿著 PC1 分開，但交界處有一些重疊，所以分類時一定會有少數個案比較難分。從圖 3 可以看到 mean 和 worst 的特徵之間有很多高度正相關。



（圖 2）訓練資料在前兩個主成分上的投影，藍色是良性、橘色是惡性



（圖 3）30 個特徵的相關熱圖，橘色是正相關、藍色是負相關

2 分析方法

資料切分與前處理

依類別分層抽樣，每一類取 80% 當訓練集，共 454 筆，剩下 115 筆當測試集。我建立的數值設計矩陣只放 30 個預測變數，Class 不會放進去。切好的結果存在 data/data_split.csv，這樣重跑程式會用同一批測試個案。然後照講義先切分，再處理的流程，中位數填補、標準化和 PCA 我都只用訓練集來算，算完再套到測試集上，也就是測試集只有在最後評估時使用。

我使用訓練集來做 PCA，把 30 個特徵轉成主成分，依解釋的變異量由大到小排序，每一個都是 30 個特徵的加權組合。取最前面的 PC1 到 PC5，分別解釋 44.27%、18.81%、9.40%、6.38%、5.68% 的變異，加起來是 84.54%。從表 3 可以看到，PC1 主要和細胞核的大小、凹陷程度有關，從剛剛上面圖 2 也可以看到兩群主要是沿著 PC1 分開。然後因為講義中有說要用相同的特徵比較才公平，所以我讓四個模型都用這五個 PC。

主成分	解釋變異	權重最大的特徵	大致代表
PC1	44.27%	concave points、concavity、perimeter、radius、compactness	細胞核的大小和凹陷程度
PC2	18.81%	三個 fractal dimension 相關特徵	細胞核邊緣的複雜程度
PC3	9.40%	texture、smoothness、symmetry 的 error	量測值的變動程度
PC4	6.38%	worst texture、mean texture	紋理
PC5	5.68%	mean symmetry、mean smoothness	對稱性和平滑度

（表 3）訓練資料前五個主成分解釋的變異，以及權重最大的特徵

模型原理與假設

- **LDA**：假設兩類共用同一個共變異數矩陣，所以決策邊界是線性的，適合當容易解釋的基準模型。
- **QDA**：每一類各自估計共變異數矩陣，所以決策邊界是二次的。高維或小樣本時要注意矩陣奇異的問題，因為要估計的參數會變很多。
- **Linear SVM**：用最大間隔原則找線性決策邊界。cost 是分錯的懲罰，cost 越大就越想把訓練資料全部分對，cost 越小就可以接受比較多錯誤。
- **RBF-SVM**：用核函數得到非線性的決策邊界，要調整 Cost 和 Gamma 來避免過度擬合。gamma 決定每個支持向量影響的範圍，gamma 越大邊界越複雜，越容易過度擬合。

SVM 超參數選擇

我在訓練集裡做分層五折，每一折都重新算填補、標準化和 PCA。我一開始先照老師範例程式的設定，Linear SVM 用 cost = 1，RBF-SVM 用 cost = 1、gamma = 0.2。結果在五折交叉驗證中，RBF-SVM 的 Balanced Accuracy 只有 0.948，有 10 例 FN、13 例 FP，比 Linear SVM 還差。

選參數的標準我一開始是看 Accuracy，但發現 RBF-SVM 會選到 cost = 1、gamma = 0.01 這組，它的 Accuracy 最高，可是 Sensitivity 只有 0.929，有 12 例惡性被判成良性。所以我上網查可以怎麼辦，查到 García 等人的研究中提到，資料不平衡時 Accuracy 會偏向多數類別，而我這份資料 B 比 M 多，所以我改用研究中提到的解決方法，使用 Sensitivity 和 Specificity 的平均，也就是 Balanced Accuracy 來選，同分時選參數比較小的。最後我試了 Linear SVM 的 cost = 0.1、1、10、100 四個值，RBF-SVM 的 cost 一樣試那四個值，gamma 試 0.01、0.1、1 三個值。Balanced Accuracy 最高的那組是 Linear SVM cost = 10，RBF-SVM cost = 100、gamma = 0.01。改完之後 RBF-SVM 的 Balanced Accuracy 從 0.948 提高到 0.964，FN 從 10 例降到 7 例，Linear SVM 也從 0.962 提高到 0.967。

評估指標

我用表 4 的五個指標來評估模型。因為 M 設為陽性，所以 Sensitivity 就是惡性被正確抓出來的比例，1 減掉 Sensitivity 就是漏判率。

指標	定義	意義
Accuracy	正確的個案數 / 全部個案數	整體正確率，可能掩蓋少數類錯誤
Sensitivity	TP / 實際惡性的個案數	惡性個案被正確辨識的比例；1 − Sens. 即漏判率
Specificity	TN / 實際良性的個案數	良性個案被正確排除的比例
Precision	TP / 預測為惡性的個案數	預測為惡性者中真正惡性的比例
F1-score	Precision 和 Sensitivity 的調和平均	兼顧抓出惡性與陽性預測品質

（表 4）評估指標的定義和意義

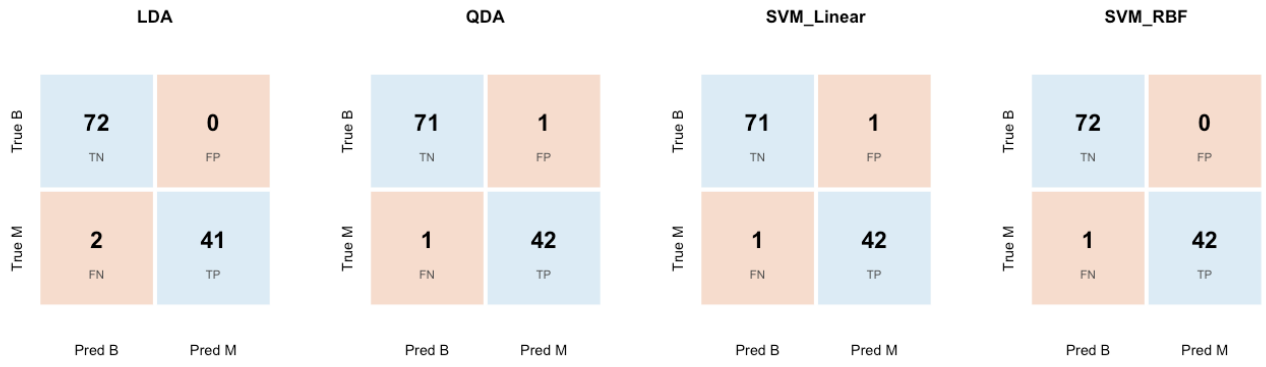
3　結果

獨立測試集表現

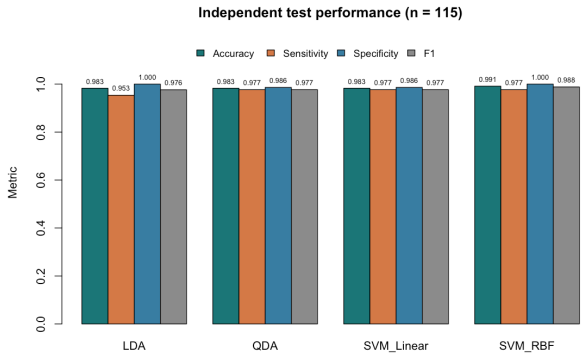
模型	Accuracy	Sensitivity	Specificity	Precision	F1	FN	FP
LDA	0.983	0.953	1.000	1.000	0.976	2	0
QDA	0.983	0.977	0.986	0.977	0.977	1	1
Linear SVM：cost = 10	0.983	0.977	0.986	0.977	0.977	1	1
RBF-SVM：cost = 100、γ = 0.01	**0.991**	0.977	**1.000**	**1.000**	**0.988**	1	0

（表 5）四個模型在同一批測試資料上的表現

講義中有提到醫療診斷不能只看 Accuracy，所以我先看 FN。我跑完 R 程式後產生了四個模型的混淆矩陣和指標比較圖。



（圖 4）四個模型的混淆矩陣，列是實際類別、欄是預測類別，左下格是 FN，右上格是 FP



（圖 5）測試集 Accuracy、Sensitivity、Specificity 與 F1 比較

從圖 4 可以看到 LDA 沒有 FP，但左下格有 2 例惡性被判成良性；QDA 和 Linear SVM 各有 1 例 FN、1 例 FP；RBF-SVM 只有 1 例 FN，沒有 FP。從圖 5 可以看到四個模型的長條高度都很接近，只有 LDA 的 Sensitivity 比較低一點。所以我認為這次 RBF-SVM 表現最好，不過測試集只有 43 例惡性，差 1 個 FN 而已，還不能說哪個模型一定比較好。

4　30 個高度相關特徵對 QDA 的影響

若是直接用 30 個原始特徵，QDA 每一類要估計 465 個共變異數參數，但訓練集裡惡性只有 169 筆。而且 radius、perimeter、area 都在描述細胞核大小，相關係數大約 0.99，這會讓共變異數矩陣接近奇異。

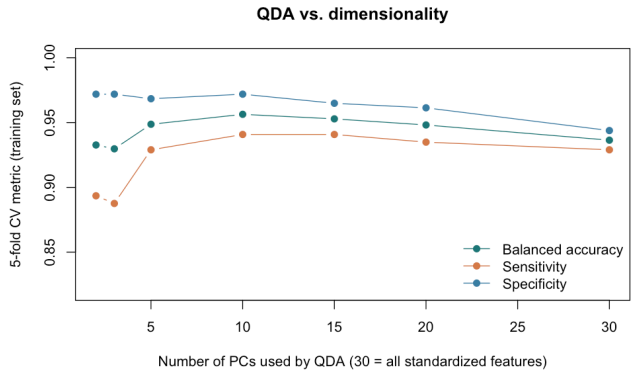
我用 R 算了每一類共變異數矩陣的條件數，從表 6 可以看到，原始特徵的條件數是 10^4 到 10^5，代表有些方向的變異非常小，QDA 算反矩陣時會在這些方向給很大的權重，資料有一點誤差就會影響分類。改用前五個 PC 之後，條件數降到 10 以下，參數也從 465 個變成 15 個。

特徵空間	每類共變異數參數	B 類條件數	M 類條件數
標準化原始 30 特徵	465	167,700	51,459
前 5 個主成分	15	7.1	9.3

（表 6）訓練集各類別共變異數矩陣的條件數，也就是最大特徵值除以最小特徵值，條件數越大，算反矩陣越不穩定

為了了解原因，我上網查到 Friedman 在 1989 年提出的 Regularized Discriminant Analysis。研究中提到，他發現樣本數不夠多時，共變異數矩陣的特徵值會失真，大的被高估、小的被低估，QDA 就會受到這些小特徵值方向影響。他的做法是讓每一類的共變異數往合併的共變異數調整，再用交叉驗證選調整的程度。效果是在 40 個樣本的模擬中，錯誤率 RDA 約 0.11、LDA 0.13、QDA 0.26。他的結論是小樣本時直接用 QDA 會不穩定，要減少要估計的參數或加上調整。我這次用 PCA 降維，其實也是在減少 QDA 要估計的參數。

為了直接看對分類表現的影響，我只在訓練集內用同樣的五折 CV，比較 QDA 用不同 PC 數的結果。用 30 個 PC 就等於用全部的標準化特徵。我跑完 R 程式後產生了圖 6 和表 7。



（圖 6）QDA 使用的 PC 數與訓練集五折 CV 表現

PC 數	Bal. Acc.	Sens.	Spec.	FN	FP
2	0.933	0.893	0.972	18	8
3	0.930	0.888	0.972	19	8
5	0.949	0.929	0.968	12	9
10	0.956	0.941	0.972	10	8
15	0.953	0.941	0.965	10	10
20	0.948	0.935	0.961	11	11
30	0.936	0.929	0.944	12	16

（表 7）QDA 用不同 PC 數時的訓練集五折 CV 結果

從圖 6 可以看到線是先上升再下降。PC 太少時會少掉有用的資訊，表 7 中 Sensitivity 降到 0.89；用全部 30 維時 FP 增加到 16 例，Balanced Accuracy 降到 0.936，就是參數太多造成的過度擬合。5 到 15 個 PC 表現比較好，不過我為了讓四個模型用同樣的特徵，所以還是固定用 5 個。

5 作業問題回答

問題 1：False Negative 與 False Positive 各代表什麼？若用於初步篩檢，哪一項更需要注意？

FN 是實際是惡性，模型卻判成良性；FP 是實際是良性，模型卻判成惡性。我認為 FN 比較嚴重，因為可能會延誤診斷；FP 會讓病人多做檢查，但後續還有機會修正。若是用在初步篩檢，就要優先降低 FN，例如把判成惡性的門檻調低，但這樣 FP 會變多，所以門檻還是要看臨床情況決定。

問題 2：Linear SVM 與 RBF-SVM 比較；LDA/QDA 假設是否合理

Linear SVM 是線性邊界，RBF-SVM 可以做非線性邊界，但比較複雜，也要調 Cost 和 Gamma。**Linear SVM** 只要調 cost，計算快也比較好解釋；**RBF-SVM** 比較有彈性，但對參數很敏感。
LDA 假設兩類共用共變異數，QDA 則是各自有共變異數。從表 2 可以看到惡性組的標準差大約是良性組的 1.3 到 2.2 倍，所以我認為 LDA 的假設不完全成立，QDA 比較符合這份資料。不過 QDA 要有足夠的樣本才估得穩，所以我先做了 PCA。

問題 3：影像特徵高度相關時，為何使用 PCA 可以讓 QDA 的估計較穩定？

PCA 讓 QDA 比較穩定的原因有三個。第一，主成分之間互相正交，不會因為變數高度相關讓矩陣接近奇異。第二，每一類要估計的參數從 465 個變成 15 個，估計比較穩。第三，PCA 去掉的是變異很小的方向，這些方向剛好是 QDA 最不穩定的地方。不過我有上網查到，PCA 只看變數本身的變異，不會看要預測的結果，變異很小的主成分有時候對預測反而很重要。所以 PC 數最好也用交叉驗證來選，才能獲得最佳的結果。

6 限制與結論

這次的結果有幾個限制。第一，測試集只有 115 筆，惡性只有 43 筆，模型之間只差 1 到 2 個個案，所以差距不一定穩定，若是要比較得更可靠，應該用重複交叉驗證。第二，資料來自單一機構和特定的量測流程，換成不同醫院或儀器時結果不一定一樣，要用在臨床前還需要外部驗證。第三，做完 PCA 後係數沒辦法直接對回原始特徵，而且講義有提醒 SVM 的分數不等於罹患機率，所以這份分析無法當作真的診斷工具。

我用五個主成分建了四個模型，在測試集上都能分出良性和惡性。若是以先降低漏判來看，QDA、Linear SVM 和 RBF-SVM 都只有 1 例 FN，比 LDA 少，其中 RBF-SVM 又沒有 FP，是這次表現最好的模型。另外發現 30 個高度相關的特徵會讓 QDA 的共變異數矩陣接近奇異，先用 PCA 降維可以讓 QDA 比較穩定。

參考資料

1. Wolberg WH, Street WN, Mangasarian OL. Breast Cancer Wisconsin Diagnostic. UCI Machine Learning Repository, 1995.
2. Street WN, Wolberg WH, Mangasarian OL. Nuclear feature extraction for breast tumor diagnosis. Proc. SPIE 1905, 1993: 861–870.
3. James G, Witten D, Hastie T, Tibshirani R. An Introduction to Statistical Learning, 2nd ed. Springer, 2021. 第 4、9、12 章
4. 課程講義：醫療疾病分類—真實研究情境的 LDA · QDA · SVM 案例
5. García V, Mollineda RA, Sánchez JS. Theoretical analysis of a performance measure for imbalanced data. 20th International Conference on Pattern Recognition, ICPR 2010: 617–620.
6. Friedman JH. Regularized discriminant analysis. Journal of the American Statistical Association, 1989; 84: 165–175.
7. Jolliffe IT. A note on the use of principal components in regression. Applied Statistics, 1982; 31: 300–303.